

קורס למידת מכונה

מטלת סיכום- חלק 2

בניית מודל חיזוי דירוג סרטים

דוח מטלת הסיכום



מרצה: ד"ר חן חג'ג'

מגישים:

שקד אמסלם (318568870)

זוהי סחייק (200039725)

קישור לגיט: <https://github.com/Shakedams/imdb-rating-prediction>

01/06/2026

תוכן עניינים:

3.....	תיאור הדאטה המעובד וטבלת הפיצ'רים
4.....	פונקציית prepare_data
4.....	השוואת מודלים Fold CV-10 ומדדי ביצועים
5.....	ניתוח חשיבות פיצ'רים
5.....	Error analysis
7.....	Fairness analysis
8.....	Data Leakage
9.....	מסקנות
10.....	AI usage log
11.....	נספחים

תיאור הדאטה המעובד וטבלת הפיצ'רים:

תיאור הדאטה המעובד:

לאחר ניקוי וסידור הנתונים, הוספו שדות והשלמו נתונים ממקורות חיצוניים. בשלב prepare_data המרנו נתונים לערכים אחידים וביצענו סטנדרטיזציה (פירוט בהמשך). הסרנו שדות שעלולים לגרום ל Data Leakage שלא יכללו בפיצ'רים של המודל. הדאטה הסופי שנכנס למודל כלל רק סרטים עם דירוג קיים, עמודת המטרה היא averageRating. בדאטה המעובד יש בסיס לבניית פיצ'רים שיעזרו לאמן את המודל.

טבלת פיצ'רים: (מצורפת גם בנספחים)

מס'ד	הפיצ'רים	סוג פיצ'ר	תיאור נוסחה	מתייבשה
1	startYear	גלמי	שנת יציאת הסרט	מאפשר למודל ללמוד הבדלים בין תקופות ושיעורים בטעם הקהל לאורך השנים.
2	years since 2000	נומרי מורכב	startYear - 2000	מייצג את מרחק השנה מתקופת בסיס, בצורה נוחה יותר למודל.
3	runtimeMinutes	גלמי	משך הסרט בדקות	אורך הסרט עשוי להשפיע על חווית הצפייה ועל הדירוג.
4	log runtime	נומרי מורכב	$\log(1 + \text{runtimeMinutes})$	מרכז השפעה של סרטים ארוכים מאוד ומייצב את הסקאלה.
5	log budget	נומרי מורכב	$\log(1 + \text{budget_usd})$	מודד סדר גודל של תקציב בלי לתת משקל קיצוני לתקציב ענק.
6	is missing budget	Missing Indicator	budget_usd חסר, 1 אחרת 0	חוסר בתקציב יכול להעיד על סרט קטן/פחות מתועד ולכן עשוי להיות מידע חשוב.
7	feat actor hist avg	נומרי מורכב	ממוצע דירוגי העבר של שחקני הסרט, רק סרטים משנים קודמות	בודק האם שחקנים עם הצלחות עבר נוטים להשתתף בסרטים עם דירוג גבוה יותר.
8	feat actor recent avg	נומרי מורכב	ממוצע דירוגי 3 הסרטים האחרונים של כל שחקן לפני שנת הסרט	מודד מומנטום עדכני של השחקנים ולא רק ממוצע קריירה כללי.
9	feat actor max	נומרי מורכב	הממוצע ההיסטורי הגבוה ביותר מבין שחקני הסרט	בודק האם כוכב חזק אחד יכול להשפיע על חיווי הדירוג.
10	feat actor count avg	נומרי מורכב	ממוצע מספר הסרטים הקודמים של שחקני הסרט	מודד ניסיון קודם של הקאסט בתעשייה.
11	feat actor genre avg	נומרי מורכב	ממוצע דירוגי עבר של השחקנים בויאורים של הסרט בלבד	בודק התאמה של השחקנים לז'אנר הספציפי של הסרט.
12	feat cast exp std	נומרי מורכב	סטיות תקן של מספר סרטי העבר של שחקני הסרט	מודד האם הקאסט מורכב משילוב של ותיקים וחדשים.
13	feat actor rating std	נומרי מורכב	ממוצע סטיות התקן של דירוגי הקריירה של השחקנים	מודד עד כמה ביצועי השחקנים בעבר יציבים או לא צמודים.
14	feat n proven stars	נומרי מורכב	מספר שחקנים עם לפחות 3 סרטי עבר וממוצע דירוג ≥ 7.0	מודד כמה שחקנים בעלי רקורד חזק קיימים בסרט.
15	feat director hist avg	נומרי מורכב	ממוצע דירוגי סרטי עבר של הבמאי לפני שנת הסרט	במאי עם רקורד חזק עשוי להיות קשור לדירוג גבוה יותר.
16	feat director genre avg	נומרי מורכב	ממוצע דירוגי עבר של הבמאי בויאורים של הסרט	בודק האם הבמאי מצליח במיוחד בז'אנר המסוים.
17	feat director rating std	נומרי מורכב	סטיות תקן של דירוגי סרטי העבר של הבמאי	מודד יציבות או תנודתיות באיכות הסרטים הקודמים של הבמאי.
18	feat writer hist avg	נומרי מורכב	ממוצע דירוגי סרטי עבר של הסטריטאים לפני שנת הסרט	הסטריטאים עם הצלחות עבר עשויים לתרום לדירוג גבוה יותר.
19	feat producer hist avg	נומרי מורכב	ממוצע דירוגי סרטי עבר של עד 3 המפיקים הראשונים לפני שנת הסרט	מודד ניסיון והצלחות עבר של ההפקה.
20	feat best crew	נומרי מורכב	$\max(\text{director hist avg, writer hist avg, producer hist avg})$	בודק האם איש צוות חזק במיוחד יכול למשוך את חיווי הסרט כלפי מעלה.
21	feat genre year trend	נומרי מורכב	ממוצע שיפוט מגמת דירוג הז'אנרים לפי שנים קודמות	מודד האם הז'אנר נמצא בתקופה של עלייה או ירידה בדירוגים.
22	feat genre year rolling	נומרי מורכב	ממוצע דירוג הז'אנרים בחלוף 5 שנים קודמות	מודד את רמת ההצלחה העדכנית של הז'אנר בתקופה הקרובה לשנת הסרט.
23	feat runtime genre dev	נומרי מורכב	$\text{runtimeMinutes} - \text{זמן זמן קריצה של ז'אנרי הסרט}$	בודק האם הסרט ארוך או קצר ביחס למקובל בז'אנר שלו.
24	feat franchise avg	נומרי מורכב	ממוצע דירוגי סרטים קודמים באותה סדרה לפני שנת הסרט	סרט המשך עשוי להיות מושפע מהצלחת סרטים קודמים בסדרה.
25	feat franchise count	נומרי מורכב	מספר סרטים קודמים באותה סדרה לפני שנת הסרט	מודד עד כמה הסרט שייך לסדרה מבוססת.
26	feat is franchise	בינארי	1 אם קיימים סרטים קודמים באותה סדרה, אחרת 0	מבדיל בין סרט עצמאי לבין סרט שהוא חלק מסדרה קיימת.
27	feat collab dir actor avg	נומרי מורכב	ממוצע דירוגי עבר של שיתופי פעולה בין הבמאי לשחקני הסרט	בודק האם שילוב מוכר של במאי ושחקנים הצליח בעבר.
28	feat collab dir actor count	נומרי מורכב	מספר שיתופי פעולה קודמים בין הבמאי לשחקני הסרט	מודד ניסיון משותף בין הבמאי לקאסט.
29	feat collab dir writer avg	נומרי מורכב	ממוצע דירוגי עבר של שיתופי פעולה בין הבמאי להסטריטאים	בודק האם צוות יצירתי שעבד יחד בעבר נוטה להצליח.
30	n actors	נומרי מורכב	מספר שחקנים מובילים מזוהים בסרט	מודד גודל קאסט בסיסי ומשמש גם לאינטראקציות.
31	n actors sq	נומרי מורכב	$n \text{ actors}^2$	מאפשר למודל לזהות השפעה לא ליניארית של מספר השחקנים.
32	is doc or no cast	בינארי	1 אם הסרט דוקומנטרי או שאין קאסט מזוהה, אחרת 0	דוקומנטריים וסרטים בלי קאסט רגיל שונים מסרטי עלילה מבחינת מבנה הדיאלוג.
33	is english	בינארי	1 אם Language כולל English, אחרת 0	שפת הסרט יכולה להיות קשורה לקהל יעד, חשיפה וסוג הפקה.
34	is us	בינארי	1 אם Country כולל United States או USA, אחרת 0	סרטים אמריקאיים עשויים להיות בעלי מאפייני הפקה והפצה שונים.
35	is major studio	בינארי	1 אם TMDB ויהה סטודיו מרכזי, אחרת 0	סטודיו גדול עשוי להעיד על הפקה מסחרית, תקציב וחשיפה שונים.
36	has plot	בינארי	1 אם קיימת עלילה, אחרת 0	עצם קיום תקציר עלילה יכול להעיד על רמת תיעוד וזמינות מידע.
37	plot word count	נומרי מורכב	מספר המילים בעלילה	אורך התקציר עשוי להעיד על מורכבות/פירוט הסרט ועל זמינות מידע.
38	n genres	נומרי מורכב	מספר הז'אנרים של הסרט	מודד עד כמה הסרט משלב כמה סוגי תוכן.
39	has release date	בינארי	1 אם קיים release month, אחרת 0	זמינות תאריך יציאה יכולה להעיד על איכות/שלמות המידע.
40	title length	נומרי מורכב	מספר התווים בשם הסרט	שם ארוך או קצר במיוחד יכול לשקף סוג סרט או סגנון שיווקי.
41	title word count	נומרי מורכב	מספר המילים בשם הסרט	מודד מבנה תוכנית הסרט באופן פשוט.
42	title has colon	בינארי	1 אם בשם הסרט יש נקודתיים, אחרת 0	נקודתיים נפוצות בסרטי המשך/תת-תוכניות ולכן עשויות לרמוז על Franchise.
43	title has number	בינארי	1 אם בשם הסרט מופיע מספר, אחרת 0	מספר בשם יכול לרמוז על סרט המשך או מותג קיים.
44	is missing actor hist	Missing Indicator	1 אם הסרט היסטוריית שחקנים, אחרת 0	חוסר היסטוריה לשחקנים עשוי להעיד על קאסט פחות מוכר.
45	is missing director	Missing Indicator	1 אם הסרט היסטוריית במאי, אחרת 0	חוסר היסטוריה לבמאי עשוי להעיד על במאי חדש או מידע חסר.
46	is missing writer	Missing Indicator	1 אם הסרט היסטוריית הסטריטאים, אחרת 0	חוסר היסטוריה להסטריטאים עשוי להעיד על צוות פחות מוכר או מידע חסר.
47	horror x runtime	אינטראקציה	$\text{g_Horror} \times \text{runtimeMinutes}$	בודק השפעה משולבת של ז'אנר האימה ואורך הסרט על הדירוג.
48	doc x runtime	אינטראקציה	$\text{g_Documentary} \times \text{runtimeMinutes}$	בודק השפעה משולבת של סרט דוקומנטרי ואורך הסרט על הדירוג.
49	n actors x rt	אינטראקציה	$n \text{ actors} \times \text{runtimeMinutes}$	בודק האם השפעת אורך הסרט משתנה לפי גודל הקאסט.
50	actor x director	אינטראקציה	$\text{feat actor hist avg} \times \text{feat director hist avg}$	בודק שילוב בין איכות היסטורית של הקאסט לבין איכות היסטורית של הבמאי.
51	actor x genre rolling	אינטראקציה	$\text{feat actor hist avg} \times \text{feat genre year rolling}$	בודק האם קאסט חזק משפיע יותר בז'אנר שנמצא בתקופה טובה.
52	writer x director	אינטראקציה	$\text{feat writer hist avg} \times \text{feat director hist avg}$	בודק התאמה בין רקורד ההסטרטאים לרקורד הבמאי.
53	feat actor sq	נומרי מורכב	$\text{feat actor hist avg}^2$	מאפשר לזהות השפעה לא ליניארית של איכות השחקנים.
54	feat director sq	נומרי מורכב	$\text{feat director hist avg}^2$	מאפשר לזהות השפעה לא ליניארית של איכות הבמאי.
55	actor x budget	אינטראקציה	$\text{feat actor hist avg} \times \log \text{ budget}$	בודק שילוב בין קאסט חזק לבין תקציב גבוה.
56	director x budget	אינטראקציה	$\text{feat director hist avg} \times \log \text{ budget}$	בודק שילוב בין במאי חזק לבין תקציב גבוה.
57	best crew x genre	אינטראקציה	$\text{feat best crew} \times \text{feat genre year rolling}$	בודק האם איש צוות חזק משפיע יותר כשהז'אנר בתקופה מצוינת.
58	n actors x actor avg	אינטראקציה	$n \text{ actors} \times \text{feat actor hist avg}$	בודק האם מספר השחקנים משנה את השפעת איכות הקאסט.
59	actor recent x hist	אינטראקציה	$\text{feat actor recent avg} \times \text{feat actor hist avg}$	בודק שילוב בין הצלחה עדכנית לבין הצלחה היסטורית של השחקנים.
60	actor max x genre	אינטראקציה	$\text{feat actor max} \times \text{feat genre year rolling}$	בודק האם כוכב מוביל משפיע יותר בז'אנר עם מגמת דירוג טובה.
61	g_GanerName	בינארי	עבור כל ז'אנר מרכזי נוצרה עמודה בינארית המקבלת 1 אם הסרט שייך לז'אנר, אחרת 0	מאפשר למודל לזהות השפעה ספציפית של ז'אנר ספציפי על הדירוג. Genre One-Hot.
62	plot_final	טקסטואלי	העלילה לאחר ניקוי; במודל עזרת TF-IDF ולאחר מכן SVD	מאפשר למודל להשתמש במילים ובנשואים מתוך תקציר העלילה בלי להשתמש במידע לאחר יציאת הסרט.
63	lang_primary	קטגוריאל	השפה הראשונה מתוך Language	מייצג את שפת הסרט המרכזית בצורה שהמודל יכול ללמוד ממנה.
64	country_primary	קטגוריאל	המדינה הראשונה מתוך Country	מייצג את מדינת ההפקה המרכזית ומשקל הבדלים בין שווקים.
65	content_rating	קטגוריאל	גרמול certification לקבוצות PG-13 / R / unknown	סיווג הגבלת גיל צפייה, מאפשר למודל לזהות מה הוא קהל היעד של הסרט, ³ על היעד עשוי להשפיע על הדירוג
66	release season	קטגוריאל	release month → awards / summer / dump / regular / unknown	עונת יציאה עשויה לשקף אסטרטגיית הפצה וסוג סרט.

פונקציית prepare_data:


כנדרש במטלה בסעיף 3.1 הגדרנו פונקציית `prepare_data(df)` אשר מקבלת דאטה ומחזירה דאטה מעובד שמוכן למודל. הפונקציה עוברת על הדאטה, מנקה אותה, יוצרת פיצ'רים חדשים ומורידה את העמודות שלא רלוונטיות למודל. תיעוד שלבים:

1. **הגדרנו את הפונקציה `prepare_data`** שמקבלת ומחזירה טבלת נתונים מסוג `data frame`. הפונקציה יוצרת עותק כדי לא לבצע שינויים בדאטה המקורי.
2. **ניקוי הדאטה** ע"י המרת מספרים לערך מספרי (בעיקר ב `runtimeMinutes` ו `startYear`), החלפת ערכים בעייתיים והגדרת חסרים כ `NaN`. המטרה ליצור אחידות ערכים למודל.
3. **סידור הנתונים**: שחקנים: יצירת עמודות מזהים של שחקנים במידה והיא חסרה בדאטה שקיבלנו (כדי שהפונקציה תוכל לרוץ על העמודה הזאת בדאטה גם אם היא לא קיימת דאטה שקיבלנו). נוודא שהתכן בעמודות שחקנים הוא רשימה של מזהי שחקנים ולא מחרוזות שנראית כמו רשימה כדי שיהיה פורט אחיד.
ז'אנר: נסדר את הערכים בעמודות ז'אנר ובמידה ואין אחד ניצור עמודה כזו, נסדר את הז'אנרים לפורמט אחיד.
עלילה: נסדר וננקה את תקציר העלילה על ידי הסרת תווים, רווחים וסימונים מיותרים והכנת טקסט העלילה לניתוח טקסטואלי, הסרנו מידע שעלול לגרום ל `data leakage` (הצלחה בקופות, סרטי המשך, פרסים וכדומה).
4. **ביצענו `One Hot Encoding`** לז'אנרים המרכזיים ברשימה כדי להפוך אותם לפיצ'רים מספריים עבור המודל.
5. **עשינו הנדסת פיצ'רים ו `Interaction Feature`** מפורט בטבלת הפיצ'רים.
6. **בחירת עמודות רלוונטיות למודל** יצרנו `DF` שמכיל משתנים שהמודל ישתמש בהם.
7. **התאמנו את הפלט למבנה הנתונים** שעליו אימנו את המודל והשלמנו עמודות פיצ'ר חסרות לצורך התאמה למבנה שעליו אומן המודל.
8. **לבסוף ביצענו בדיקת תקינות**: בדקנו שהפונקציה מחזירה את מספר השורות הנכון ושאינן עמודות שיכולות לגרום ל-`data leakage`. הפלט הסופי של `prepare_data` הוא 85 עמודות: 80 פיצ'רים מספריים, פיצ'ר טקסט אחד ו 4 משתנים קטגוריאליים.

השוואת מודלים Fold CV-10 ומדדי ביצועים:

מדדי הביצועים:

Model	RMSE mean	RMSE std	MAE mean	MAE std	R2 mean	R2 std
Elastic Net	1.0705	0.0099	0.809	0.0071	0.4134	0.0123
Random Forest	1.0505	0.009	0.793	0.0054	0.4352	0.0089



המודל הטוב ביותר מבחינת `Random Forest`, יש לו את `RMSE` הנמוך יותר. מדדי סטיית התקן בטבלה נמוכים לכן התוצאות ב `Fold CV-10` יציבות.


מהגרפים והטבלה ניתן לראות ש `Elastic Net` הוא המודל הפחות טוב מבין המודלים שבדקנו, יש לו R^2 נמוך ואת `RMSE` ו `MAE` גבוהים. `Random Forest` טוב יותר מ `Elastic Net` בכל המדדים.

ניתוח חשיבות פיצ'רים:**Elastic Net**

Elastic Net				
דירוג	פיצ'ר	עוצמה coef	כיוון השפעה	פירוש
1	release_season	0.1983	חיובי ↑	לעונת יציאת הסרט יש השפעה חיובית על חיזוי הדירוג.
2	g_Documentary	0.1819	חיובי ↑	לסרטים בז'אנר דוקומנטרי יש השפעה חיובית על חיזוי הדירוג.
3	runtimeMinutes	0.1653	חיובי ↑	לאורך הסרט יש השפעה חיובית על חיזוי הדירוג.
4	feat_director_sq	0.1611	שלילי ↓	ערך גבוה בפיצ'ר זה של הבמאי מקטין את חיזוי הדירוג.
5	feat_actor_sq	0.1189	שלילי ↓	ערך גבוה בפיצ'ר זה של השחקנים מקטין את חיזוי הדירוג.

הפיצ'רים המשפיעים ביותר במודל זה הם עונת יציאת הסרט, ז'אנר דוקומנטרי, אורך הסרט ומדדי עבר של הבמאי והשחקנים. החיזוי מבוסס על הצלחות עבר של אנשי הצוות ומאפיינים נוספים של הסרט.

פיצ'רי Plot SVD שנוצרו מתוך טקסט העלילה אינם נכללים בפיצ'רים המובילים אבל תרומתם המצטברת למודל גבוהה (61.6%).

**Random Forest**

Random Forest				
דירוג	פיצ'ר	Importance ב-RF	פירוש	
1	feat_actor_genre_avg	0.1059	הפיצ'ר החשוב ביותר ב-RF, ומראה שהמודל מתחשב בהצלחות עבר של שחקנים בתוך ז'אנרים דומים.	
2	feat_genre_year_rolling	0.084	המודל מתייחס למוצע דירוגים היסטורי של ז'אנר לאורך השנים כדי לחזות דירוג.	
3	feat_genre_year_trend	0.0576	הפיצ'ר מופיע גם ב-Elastic Net, ושם הכיוון חיובי — כלומר מגמת שיפור בז'אנר מעלה את חיזוי הדירוג.	
4	feat_best_crew	0.0463	המודל נותן חשיבות לאיכות או הצלחות עבר של אנשי הצוות החזקים ביותר בסרט.	
5	actor_x_genre_rolling	0.0302	המודל בודק שילוב בין שחקנים לבין ז'אנר, כלומר האם שחקנים מסוימים מצליחים יותר בז'אנרים מסוימים.	

מודל זה מבסס את החיזוי על ניסיון והצלחות עבר של השחקנים והצוות, יחד עם מגמות היסטוריות של ז'אנרים וקשרים מורכבים בין ז'אנר, שחקנים ושנה.

לסיכום, לחלק מהפיצ'רים המובילים ב Random Forest יש מקדמים חיוביים ב-Elastic Net דבר שמעיד על הסכמה חלקית בין המודלים. בנוסף, בשניהם חלק מהפיצ'רים המשפיעים קשורים למאפייני הסרט. הפיצול ביניהם בא לידי ביטוי בכך שהמודלים לא מסכימים על 5 הפיצ'רים החשובים ביותר, ב-Elastic Net הם ישירים ולינאריים וב Random Forest הם מורכבים ואינטרקטיביים.

Error analysis

ביצענו את Error analysis על מודל Random Forest כי הוא הטוב ביותר מבין המודלים שבדקנו.

מקרי חיזוי OVERPREDICTIONS

TOP 10 OVERPREDICTIONS (RF)						
מס'ד	שם הסרט	דירוג אמיתי	חיזוי המודל	שגיאה	שנה	ז'אנר
1	Justin Bieber: Always Believing	1	6.96	-5.96	2012	Documentary, Music
2	Ramo Trip	1.4	7.33	-5.93	2012	Documentary
3	Tribalism Is Killing Us	1.3	7.2	-5.9	2019	Documentary
4	Occupy Los Angeles	2.3	8.16	-5.86	2012	Documentary, Drama, Western
5	Brush with Life: The Art of Being Edward Biberman	1.5	7.3	-5.8	2007	Documentary
6	Rape of the Soul	1.7	7.47	-5.77	2006	Documentary, History
7	Kurz	1.2	6.96	-5.76	2023	Documentary
8	Zoo School	1.1	6.78	-5.68	2019	Animation
9	Play in the Gray	1.3	6.97	-5.67	2009	Biography, Comedy, Documentary
10	Nomad & Roadrunner	1.9	7.53	-5.63	2021	Drama


סרטים אלו דורגו נמוך באופן קיצוני. המודל חזה מדד יחסית ממוצע ולא הצליח לנבא את הדירוג הקיצוני של 1 שקרה במציאות. ז'אנר שחוזר על עצמו הוא Documentary, כנראה סרטים מסוג זה נוטים לקבל דירוג קיצוני נמוך בגלל תגובת קהל חריגה.

Obama in NC: The Path to | Brush with Life: The Art of Being Edward | Justin Bieber: Always Believing History: סרטים דוקומנטריים שיכולים לעורר רגש קיצוני אצל הצופים (מבחינה חברתית ופוליטית) ובכך לגרום דירוג קיצוני שלילי שהמודל לא יכול לחזות. כנראה המודל חזה את דירוג הסרטים בהתאם למדד הצלחת אנשי הצוות בפרויקטים קודמים, אנשי הצוות היותר מצליחים השפיעו על דירוג המודל.

Play in the Gray סרט נישתי, מעט אנשים דרגו אותו בצורה קיצונית שלילית. כנראה דורג גבוה בגלל פיצ'רים של מדד הצלחת אנשי הצוות בפרויקטים קודמים וזה הוביל לחיזוי גבוה מהמציאות, המודל חזה לסרט ערך ממוצע יחסית בהתאם לציוני אנשי הצוות הפחות מצליחים בצוות.

Rape of the Soul גילינו שבאתר ממוצע דירוג ההצבעות הוא בעצם 8.3 (למרות שכתוב 1.7) המודל שלנו חזה 7.47 דירוג קרוב למציאות. יכול להיות שהאתר פסל חלק מההצבעות ולכן הסרט קיבל דירוג שונה.

(קישור - https://www.imdb.com/title/tt0808438/ratings/?ref_=tt_ov_rat)



מקרי חיזוי UNDERPREDICTIONS:

TOP 10 UNDERPREDICTIONS (RF)					
מס"ד	שם הסרט	דירוג אמיתי	חיזוי המודל	שגיאה	שנה
1	Annabel Lee	8.8	4.19	4.61	2009
2	Nochebuena	8.9	4.5	4.4	2023
3	One Night Out	9	4.72	4.28	2018
4	Planet Ibsen	8.6	4.34	4.26	2005
5	Valentine Crush	8.3	4.05	4.25	2021
6	Ganga Jaisan Mai Hamar	9.1	4.87	4.23	2004
7	Joshua	9.2	4.97	4.23	2020
8	Gud förbannat vilken jävla show! Med Leif & B	9.5	5.29	4.21	2023
9	Ice Nine Kills Presents: Welcome to Horrorwoo	8.4	4.21	4.19	2024
10	He Say, She Say	9	4.87	4.13	2021

המודל מתקשה לזהות סרטים חריגים שיש להם דירוג גבוה. בבדיקת פילוג הדירוג לסרטים אלה יש התפלגות הצבעות מקוטבת שנוטה לדירוג גבוה יותר, ההתפלגות יכולה להעיד קהל נישתי. כנראה המודל מתקשה לחזות סרטים בז'אנרים Horror ו Thriller כי הם חוזרים על עצמם. מתוך הסרטים יש 4 שהשפה ו/או המדינה בהם היא לא אנגלית ו/או ארה"ב, המודל נוטה לחזות נמוך סרטים כאלה כנראה בגלל שלא היו לו מספיק דוגמאות.

Annabel Lee | He Say, She Say: סרטי Thriller עם מספר מדרגים נמוך אבל הדירוג קיצוני חיובי. כנראה סרטים אלה נוטים לקבל דירוג נמוך במודל.

Gud förbannat vilken jävla show! Med Leif & Billy | Joshua | Ganga Jaisan Mai Hamar | One Night Out: המודל כנראה חזה דירוג נמוך מפני שהסרטים סרטים זרים.

Genre distribution among 20 outliers:

Documentary	8
Thriller	4
Drama	3
Comedy	3
Horror	2
Music	1
Western	1
History	1

Outlier Pattern Analysis ניתוח דפוסים בחריגים:

הז'אנרים שמופיעים הכי הרבה בין החריגים הם Documentary ו Thriller, המודל מתקשה לחזות להם דירוג מדויק.

השנה הממוצעת של הסרטים החריגים קרובה מאוד לשנה הממוצעת של כלל הסרטים ולכן נסיק שהשנה כנראה אינה גורם לטעויות.

Year stats:

Outliers	mean year: 2015
Full set	mean year: 2014

המודל חזה לסרטים עם דירוג נמוך מאוד דירוג די גבוהה ולסרטים עם דירוג גבוהה מאוד דירוג די נמוך. המודל "בורח לאמצע" הוא מתקשה לחזות דירוג של סרטים שנמצאים "בקצוות".

Actual rating averages:

Over-predicted	mean: 1.47 (low ratings → model expected higher)
Under-predicted	mean: 8.88 (high ratings → model didn't see them coming)

מסמך בלתי מסווג

01/06/2026

--- Model Outlier Comparison ---

EN outliers (20): 20 movies

RF outliers (20): 20 movies

Overlap: 8 (40%)

On the 8 shared outliers:

EN MAE: 5.524

RF MAE: 5.477


EN-only outliers (12): RF MAE on those = 4.326

RF-only outliers (12): EN MAE on those = 4.963

השוואת חריגים בין מודלים Elastic Net ו Random Forest

יש חפיפה בין המודלים על 40% מהסרטים, כנראה אלו סרטים שקשה לחזות להם דירוג קרוב למציאות כי שני המודלים שלנו טעו בהם.

לפי MAE, Random Forest מעט יותר מדויק מ Elastic Net בחריגים.



המודל Random Forest (1) חוזה בצורה טובה יחסית סרטים שמדורגים באמצע אבל מתקשה בקצוות, (2) רוב השגיאות מרוכזות סביב האפס, ברוב המקרים השגיאה לא גדולה אבל במקרי קצה הטעויות משמעותיות, ההתפלגות די סימטרית. (3) ניתן לראות בקורלציה בין שני המודלים שהם נוטים לטעות באותו כיוון באותם סרטים.

הצעות לשיפור פיצ'רים חדשים:


- is_non_western_production לפי מדינה ושפה בסרט, הפיצ'ר יעזור לזהות סרטים זרים ולא להעניש אותם אוטומטית.
- documentary_effect לפי ז'אנר ומילים בעלילה (כגון: דת, מדינה, אישות וכדומה) המודל יזהה סרטים דוקומנטריים שיכולים ליצור תגובה שלילית אצל הצופים שתגרום לירידה בדירוג הסרט.
- niche_audience יבדוק נישטיות של סרט לפי ז'אנר, שפה ומדינה, המודל יקבל אומדן לנישתיות הסרט דבר שיכול לעזור לו בחיזוי דירוג של סרטים בקצוות.

Fairness analysis**ניתוח הצגה חזותית:**

סיכום נתונים			
מסקנה	איפה המודל יותר מדויק?	איפה המודל פחות מדויק?	חתך
קיימים הבדלים בין ז'אנרים. Thriller הוא הז'אנר עם השגיאה הגבוהה ביותר. המודל פחות מדויק בסרטים שאינם אמריקאיים.	Documentary	Thriller	Genre
המודל מתקשה יותר עם סרטים חדשים יחסית.	US	Non-US	Country
ככל שהתקציב גבוה יותר, השגיאה קטנה יותר.	2000	2020	Decade
חסר בנתוני תקציב קשור לחיזוי פחות מדויק.	High	Low	Budget
חסר בנתוני תקציב קשור לחיזוי פחות מדויק.	Has budget	Missing budget	Data Availability

Fairness Analysis					
חתך	קבוצה	N	RMSE	MAE	אחוזי הבדל ב-RMSE
Genre	Thriller	8512	1.0978	0.84336	4.5
	Comedy	18901	1.05919	0.80183	0.8
	Drama	33172	1.00734	0.76342	-4.1
	Romance	8362	0.97996	0.74214	-6.7
	Documentary	11501	0.94432	0.69171	-10.1
Country	Non-US	55467	1.06249	0.8027	1.1
	US	13889	1.00138	0.75438	-4.7
Decade	2020	18196	1.09846	0.83195	4.6
	2010	33605	1.03897	0.78321	-1.1
	2000	17555	1.02136	0.77148	-2.8
Budget	Low	5031	1.11314	0.86387	6
	Medium	5043	0.96445	0.72073	-8.2
	High	4957	0.90875	0.68645	-13.5
Data Availability	Missing budget	54325	1.06421	0.8029	1.3
	Has budget	15031	0.99958	0.75733	-4.9

01/06/2026

**דיון:**

חתכים בהם המודל פחות מדויק ולמה:
 Genre: בז'אנר Thriller RMSE גבוה בכ-4.5% מהממוצע, לעומת Documentary שבו השגיאה נמוכה מהממוצע בכ-10.1%.
 אנחנו חושבים שלמודל קשה לחזות את הדירוג כי בדרך כלל סרטי Thriller שונים מאוד אחד מהשני.
 Budget המודל פחות מדויק בסרטים בעלי תקציב נמוך, RMSE גבוה בכ-6% מהממוצע, אך סרטים עם תקציב גבוה המודל חוזה טוב יותר, השגיאה נמוכה מהממוצע בכ-13.5%. אנחנו חושבים שסרטים עם תקציב נמוך הם מגוונים יותר ויש להם פחות מידע זמין ולכן למודל קשה לחזות להם דירוג בצורה מדויקת.

חששות לגבי שימוש במודל בפועל:
 ישנם חששות מסוימים לשימוש במודל אך הם לא מהותיים. בעת חיזוי דירוג לסרט עם תקציב נמוך או סרטי Thriller יש לקחת בחשבון שהחיזוי לא מדויק.
 חלוקה לחסרי נתונים יכולה להיות מנבאת:
 במודל ניתן לראות שככל שיש יותר מידע הדירוג מדויק יותר, ניתן לראות זאת ב Data Availability. לכן כנראה יש bias לסרטים שיש להם יותר מידע.

Data Leakage

לפי דרישות המטלה, כדי למנוע Data Leakage הסרנו את השדות:

- averageRating
- numVotes
- BoxOffice

שדות אלו חושפים את המודל למידע שלא אמור להיות לו טרם יציאת הסרט לאקרנים.
 בעת הגדרת פיצ'רים מבוססים על אנשי הצוות בסרט (שחקנים, במאים, מפיקים, תסריטאים וכו') וז'אנר לפי תקופה, חישבנו את המדדים לפי נתונים מהעבר.
 ב Pipeline ביצענו את כל שלבי העיבוד כך שמודל לא קיבל מידע מנתוני הבדיקה. בכל בדיקה ב CV המודל התאמן רק על נתוני האימון ונבדק על נתוני הבדיקה (שלא נחשף אליהם קודם).
 בנוסף וידאנו Target Encoding בטוח ו TF-IDF ללא זליגת מידע.
 לבסוף, בוצעו בדיקות אימות אוטומטיות בקוד במטרה לוודא שאין שימוש בנתונים שגורמים לזליגה. בדיקות האימות בקוד עברו בהצלחה.

```
LEAKAGE VERIFICATION

[✓] Check 1: ['averageRating', 'numVotes', 'BoxOffice'] absent from features
[✓] Check 2: pipeline fits inside CV (RMSE=1.0776)
[✓] Check 3: prepare_data outputs are clean
[✓] Check 4: time filter active - year=2024 gives 6.283333333333332, year=2074 gives 6.157333333333334
[✓] Check 5: plot text cleaner strips post-release signals

[✓] All 5 leakage checks passed
```


מסקנות:**מסקנות:**

במטלה מצאנו כי המודל הטוב יותר הוא Random Forest.

תוצאות Fold CV-10 יציבות בגלל שמדדי סטיית התקן נמוכים.

המודל Elastic Net מבסס את החיזוי מאפייני הסרט ישירים כגון : הצלחות עבר של אנשי הצוות, עונת יציאה, אורך הסרט ועד. לעומת זאת המודל Random Forest מבסס את החיזוי על מגמות היסטוריות של ז'אנרים וקשרים מורכבים בין ז'אנר, שחקנים ושנה.

מגבלות:

בניתוח החריגים הופיעו הרבה סרטי Documentary ו Thriller, עם זאת בניתוח הוגנות הז'אנר שבו המודל פחות מדויק באופן בולט הוא Thriller, ו Documentary היה מדויק יותר מהמוצע. חתכים בהם המודל פחות מדויק הם Genre, Decade ו Budget. בעת חיזוי דירוג לסרט עם תקציב נמוך, סרטים עם תקציב חסר, סרטים שאינם אמריקאים, סרטים חדשים יותר וסרטי Thriller יש לקחת בחשבון שהחיזוי לא מדויק. עם זאת כל שיש יותר מידע הדירוג מדויק יותר.

בנוסף, הדאטה יכול להגביל אם הוא לא איכותי וחסרים בו נתונים.

הצעות להמשך:

- יצירת פיצ'רים נוספים שישפרו את מגבלת המודל.
- איסוף דאטה איכותי עם כמה שפחות חוסרים.
- בדיקת מודלים נוספים, כגון SVM, KNN, XGBoost.

:AI usage log

לאורך העבודה נעזרנו בAI ככלי עזר לחשיבה, תכנון, כתיבת קוד, שיפור קוד וניסוח חלקים בדוח.

נעזרנו בכלים ChatGPT, Claude ו-Gemini.

- בתחילת העבודה התייעצנו לגבי סדר הפעולות הכללי בפרויקט ואיך לגשת לעיבוד הדאטה.
- שלב הכנת הדאטה: התייעצנו לגבי דרכי ניקוי נתונים, טיפול בערכים חסרים, המרת משתנים וכדומה במטרה לכסות כמה שיותר בעיות שיכולות לצוף בעת הרצת המודל עם הדאטה של התחרות.
- שלב כתיבת הפונקציה `prepare_data`: התייעצנו כיצד לבנות תהליך עיבוד נתונים שיהיה אחיד וטוב ביותר.
- שלב הנדסת הפיצ'רים: התייעצנו על רעיונות וכיצד ניתן לממש והאם נכון להשתמש בפיצ'רים שחשבנו עליהם. נעזרנו גם כדי לבדוק שפיצ'רים חדשים אינם יוצרים `data leakage` או האם הם יכולים ליצור `data leakage`. (פיצ'רים שAI עזר לנו להוסיף למודל נמצאים בנספחים).
- שלב המודלים: התייעצנו לגבי בחירת מודלים, באיזה עוד מודלים מומלץ/ כדאי להשתמש.
- עבור `Elastic Net` התייעצנו לגבי בחירת עוצמת הרגולריזציה `alpha` ולגבי האיזון בין `Lasso` ל-`Ridge` באמצעות `l1_ratio`.
- עבור `Decision Tree` התייעצנו לגבי בחירת פרמטרים `max_depth`, `min_samples_split`, `min_samples_leaf` ו-`ccp_alpha`.
- במהלך העבודה נשענו על AI מבחינת הקוד והשיפור שלו, תיקון שגיאות, התייעלות בהרצה והתמודדות עם בעיות זיכרון שעלו בזמן עיבוד הדאטה או אימון המודלים. אימתנו שהקוד נכון ע"י בדיקתו בכמה כלי AI שונים והתייעצות עם חברים בתואר ובתעשייה.
- שלב כתיבת הדוח: נעזרנו בAI לניסוחים נקודתיים ולהמרת התוצאות שהתקבלו לטבלאות.
- אימתנו באמצעות הרצת הקוד במחברת, בדיקת שגיאות, השוואת מדדי ביצועים ובחינה האם התוצאות שהתקבלו בפועל הגיוניות.

נספחים:

טבלת פיצ'רים שנעזרנו ב – AI:

פיצ'ר	מס"ד בטבלת פיצ'רים	מס"ד
startYear	1	1
runtimeMinutes	3	2
log_runtime	4	3
log_budget	5	4
is_missing_budget	6	5
feat_actor_genre_avg	11	6
feat_cast_exp_std	12	7
feat_actor_rating_std	13	8
feat_director_genre_avg	16	9
feat_director_rating_std	17	10
feat_genre_year_rolling	22	11
feat_franchise_avg	24	12
feat_franchise_count	25	13
feat_is_franchise	26	14
feat_collab_dir_actor_avg	27	15
feat_collab_dir_actor_count	28	16
feat_collab_dir_writer_avg	29	17
n_actors	30	18
n_actors_sq	31	19
is_doc_or_no_cast	32	20
is_major_studio	35	21
has_plot	36	22
n_genres	38	23
has_release_date	39	24
title_has_colon	42	25
title_has_number	43	26
is_missing_actor_hist	44	27
is_missing_director	45	28
is_missing_writer	46	29
feat_actor_sq	53	30
feat_director_sq	54	31
actor_x_budget	55	32
director_x_budget	56	33
best_crew_x_genre	57	34
n_actors_x_actor_avg	58	35
actor_recent_x_hist	59	36
actor_max_x_genre	60	37
g_GanerName	61	38
plot_final	62	39
content_rating	65	40
release_season	66	41

01/06/2026

טבלת פיצ'רים:

מס"ד	כל הפיצרים	סוג פיצ'ר	תיאור נוסחה	מוטיבציה
1	startYear	גולמי	שנת יציאת הסרט	מאפשר למודל ללמוד הבדלים בין תקופות ושינויים בטעם הקהל לאורך השנים.
2	years_since_2000	נומרי מורכב	startYear - 2000	מייצג את מרחק השנה מתקופת בסיס, בצורה נוחה יותר למודל.
3	runtimeMinutes	גולמי	משך הסרט בדקות	אורך הסרט עשוי להשפיע על חווית הצפייה ועל הדירוג.
4	log_runtime	נומרי מורכב	$\log(1 + \text{runtimeMinutes})$	מרכך השפעה של סרטים ארוכים מאוד ומייצב את הסקאלה.
5	log_budget	נומרי מורכב	$\log(1 + \text{budget_usd})$	מודד סדר גודל של תקציב בלי לתת משקל קיצוני לתקציבי ענק.
6	is_missing_budget	Missing Indicator	budget_usd חסר 1, אחרת 0	חוסר בתקציב יכול להעיד על סרט קטן/פחות מתועד ולכן עשוי להיות מידע חשוב.
7	feat_actor_hist_avg	נומרי מורכב	ממוצע דירוגי העבר של שחקני הסרט, רק סרטים משנים קודמות	בודק האם שחקנים עם הצלחות עבר נוטים להשתתף בסרטים עם דירוג גבוה יותר.
8	feat_actor_recent_avg	נומרי מורכב	ממוצע דירוגי 3 הסרטים האחרונים של כל שחקן לפני שנת הסרט	מודד מומנטום עדכני של השחקנים ולא רק ממוצע קריירה כללי.
9	feat_actor_max	נומרי מורכב	הממוצע ההיסטורי הגבוה ביותר מבין שחקני הסרט	בודק האם כוכב חזק אחד יכול להשפיע על חיזוי הדירוג.
10	feat_actor_count_avg	נומרי מורכב	ממוצע מספר הסרטים הקודמים של שחקני הסרט	מודד ניסיון קודם של הקאסט בתעשייה.
11	feat_actor_genre_avg	נומרי מורכב	ממוצע דירוגי עבר של השחקנים בז'אנרים של הסרט בלבד	בודק התאמה של השחקנים לז'אנר הספציפי של הסרט.
12	feat_cast_exp_std	נומרי מורכב	סטיית תקן של מספר סרטי העבר של שחקני הסרט	מודד האם הקאסט מורכב משיילוב של ותיקים וחדשים.
13	feat_actor_rating_std	נומרי מורכב	ממוצע סטיות התקן של דירוגי הקריירה של השחקנים	מודד עד כמה ביצועי השחקנים בעבר יציבים או לא צפויים.
14	feat_n_proven_stars	נומרי מורכב	מספר שחקנים עם לפחות 3 סרטי עבר וממוצע דירוג ≥ 7.0	מודד כמה שחקנים בעלי רקורד חזק קיימים בסרט.
15	feat_director_hist_avg	נומרי מורכב	ממוצע דירוגי סרטי עבר של הבמאי לפני שנת הסרט	במאי עם רקורד חזק עשוי להיות קשור לדירוג גבוה יותר.
16	feat_director_genre_avg	נומרי מורכב	ממוצע דירוגי עבר של הבמאי בז'אנרים של הסרט	בודק האם הבמאי מצליח במיוחד בז'אנר המסוים.
17	feat_director_rating_std	נומרי מורכב	סטיית תקן של דירוגי סרטי העבר של הבמאי	מודד יציבות או תנודתיות באיכות הסרטים הקודמים של הבמאי.
18	feat_writer_hist_avg	נומרי מורכב	ממוצע דירוגי סרטי עבר של התסריטאים לפני שנת הסרט	תסריטאים עם הצלחות עבר עשויים לתרום לדירוג גבוה יותר.
19	feat_producer_hist_avg	נומרי מורכב	ממוצע דירוגי סרטי עבר של עד 3 המפיקים הראשונים לפני שנת הסרט	מודד ניסיון והצלחות עבר של ההפקה.
20	feat_best_crew	נומרי מורכב	$\max(\text{director_hist_avg}, \text{writer_hist_avg}, \text{producer_hist_avg})$	בודק האם איש צוות חזק במיוחד יכול למשוך את חיזוי הסרט כלפי מעלה.
21	feat_genre_year_trend	נומרי מורכב	ממוצע שיפוע מגמת דירוג הז'אנרים לפי שנים קודמות	מודד האם הז'אנר נמצא בתקופה של עלייה או ירידה בדירוגים.
22	feat_genre_year_rolling	נומרי מורכב	ממוצע דירוג הז'אנרים בחלון 5 שנים קודמות	מודד את רמת ההצלחה העדכנית של הז'אנר בתקופה הקרובה לשנת הסרט.
23	feat_runtime_genre_dev	נומרי מורכב	runtimeMinutes - הציון זמן הריצה של ז'אנרי הסרט	בודק האם הסרט ארוך או קצר ביחס למקובל בז'אנר שלו.
24	feat_franchise_avg	נומרי מורכב	ממוצע דירוגי סרטים קודמים באותה סדרה לפני שנת הסרט	סרט המשך עשוי להיות מושפע מהצלחת סרטים קודמים בסדרה.
25	feat_franchise_count	נומרי מורכב	מספר סרטים קודמים באותה סדרה לפני שנת הסרט	מודד עד כמה הסרט שייך לסדרה מבוססת.
26	feat_is_franchise	בינארי	1 אם קיימים סרטים קודמים באותה סדרה, אחרת 0	מבדיל בין סרט עצמאי לבין סרט שהוא חלק מסדרה קיימת.
27	feat_collab_dir_actor_avg	נומרי מורכב	ממוצע דירוגי עבר של שיתופי פעולה בין הבמאי לשחקני הסרט	בודק האם שילוב מוכר של במאי ושחקנים הצליח בעבר.
28	feat_collab_dir_actor_count	נומרי מורכב	מספר שיתופי פעולה קודמים בין הבמאי לשחקני הסרט	מודד ניסיון משותף בין הבמאי לקאסט.
29	feat_collab_dir_writer_avg	נומרי מורכב	ממוצע דירוגי עבר של שיתופי פעולה בין הבמאי לתסריטאים	בודק האם צוות יצירתי שעבד יחד בעבר נוטה להצליח.
30	n_actors	נומרי מורכב	מספר שחקנים מובילים מזהים בסרט	מודד גודל קאסט בסיסי ומשמש גם לאינטראקציות.
31	n_actors_sq	נומרי מורכב	n_actors^2	מאפשר למודל לזהות השפעה לא ליניארית של מספר השחקנים.
32	is_doc_or_no_cast	בינארי	1 אם הסרט דוקומנטרי או שאין קאסט מזהה, אחרת 0	דוקומנטריים וסרטים בלי קאסט רגיל שונים מסרטי עלילה מבחינת מבנה החיזוי.
33	is_english	בינארי	1 אם Language כולל English, אחרת 0	שפת הסרט יכולה להיות קשורה לקהל יעד, חשיפה וסוג הפקה.
34	is_us	בינארי	1 אם Country כולל United States או USA, אחרת 0	סרטים אמריקאיים עשויים להיות בעלי מאפייני הפקה והפצה שונים.
35	is_major_studio	בינארי	1 אם TMDb זיהה סטודיו מרכזי, אחרת 0	סטודיו גדול עשוי להעיד על הפקה מסחרית, תקציב וחשיפה שונים.
36	has_plot	בינארי	1 אם קיימת עלילה, אחרת 0	עצם קיום תקציר עלילה יכול להעיד על רמת תיעוד וזמינות מידע.
37	plot_word_count	נומרי מורכב	מספר המילים בעלילה	אורך התקציר עשוי להעיד על מורכבות/פירוט הסרט ועל זמינות מידע.
38	n_genres	נומרי מורכב	מספר הז'אנרים של הסרט	מודד עד כמה הסרט משלב כמה סוגי תוכן.
39	has_release_date	בינארי	1 אם קיים release_month, אחרת 0	זמינות תאריך יציאה יכולה להעיד על איכות/שלמות המידע.
40	title_length	נומרי מורכב	מספר התווים בשם הסרט	שם ארוך או קצר במיוחד יכול לשקף סוג סרט או סגנון שיווקי.
41	title_word_count	נומרי מורכב	מספר המילים בשם הסרט	מודד מבנה כותרת הסרט באופן פשוט.
42	title_has_colon	בינארי	1 אם בשם הסרט יש נקודתיים :, אחרת 0	נקודתיים נפוצות בסרטי המשך/תת-כותרות ולכן עשויות לרמוז על Franchise.
43	title_has_number	בינארי	1 אם בשם הסרט מופיע מספר, אחרת 0	מספר בשם יכול לרמוז על סרט המשך או מותג קיים.
44	is_missing_actor_hist	Missing Indicator	1 אם חסרה היסטוריית שחקנים, אחרת 0	חוסר היסטוריה לשחקנים עשוי להעיד על קאסט פחות מוכר.

01/06/2026

45	is_missing_director	Missing Indicator	1 אם חסרה היסטוריית במאי, אחרת 0	חוסר היסטוריה לבמאי עשוי להעיד על במאי חדש או מידע חסר.
46	is_missing_writer	Missing Indicator	1 אם חסרה היסטוריית תסריטאים, אחרת 0	חוסר היסטוריה לתסריטאים עשוי להעיד על צוות פחות מוכר או מידע חסר.
47	horror_x_runtime	אינטראקציה	$g_Horror \times runtimeMinutes$	בודק השפעה משולבת של ז'אנר האימה ואורך הסרט על הדירוג.
48	doc_x_runtime	אינטראקציה	$g_Documentary \times runtimeMinutes$	בודק השפעה משולבת של סרט דוקומנטרי ואורך הסרט על הדירוג.
49	n_actors_x_rt	אינטראקציה	$n_actors \times runtimeMinutes$	בודק האם השפעת אורך הסרט משתנה לפי גודל הקאסט.
50	actor_x_director	אינטראקציה	$feat_actor_hist_avg \times feat_director_hist_avg$	בודק שילוב בין איכות היסטורית של הקאסט לבין איכות היסטורית של הבמאי.
51	actor_x_genre_rolling	אינטראקציה	$feat_actor_hist_avg \times feat_genre_year_rolling$	בודק האם קאסט חזק משפיע יותר בז'אנר שנמצא בתקופה טובה.
52	writer_x_director	אינטראקציה	$feat_writer_hist_avg \times feat_director_hist_avg$	בודק התאמה בין רקורד התסריטאים לרקורד הבמאי.
53	feat_actor_sq	נומרי מורכב	$feat_actor_hist_avg^2$	מאפשר לזהות השפעה לא ליניארית של איכות השחקנים.
54	feat_director_sq	נומרי מורכב	$feat_director_hist_avg^2$	מאפשר לזהות השפעה לא ליניארית של איכות הבמאי.
55	actor_x_budget	אינטראקציה	$feat_actor_hist_avg \times \log_budget$	בודק שילוב בין קאסט חזק לבין תקציב גבוה.
56	director_x_budget	אינטראקציה	$feat_director_hist_avg \times \log_budget$	בודק שילוב בין במאי חזק לבין תקציב גבוה.
57	best_crew_x_genre	אינטראקציה	$feat_best_crew \times feat_genre_year_rolling$	בודק האם איש צוות חזק משפיע יותר כשהז'אנר בתקופה מוצלחת.
58	n_actors_x_actor_avg	אינטראקציה	$n_actors \times feat_actor_hist_avg$	בודק האם מספר השחקנים משנה את השפעת איכות הקאסט.
59	actor_recent_x_hist	אינטראקציה	$feat_actor_recent_avg \times feat_actor_hist_avg$	בודק שילוב בין הצלחה עדכנית לבין הצלחה היסטורית של השחקנים.
60	actor_max_x_genre	אינטראקציה	$feat_actor_max \times feat_genre_year_rolling$	בודק האם כוכב מוביל משפיע יותר בז'אנר עם מגמת דירוג טובה.
61	g_GanerName	בינארי	עבור כל ז'אנר מרכזי נוצרה עמודה בינארית המקבלת 1 אם הסרט שייך לז'אנר, אחרת 0	מאפשר למודל לזהות השפעה ספציפית של ז'אנר ספציפי על הדירוג. Genre One-Hot Features.
62	plot_final	טקסטואלי	העלילה לאחר ניקוי; במודל עוברת TF-IDF ולאחר מכן SVD	מאפשר למודל להשתמש במילים ובנושאים מתוך תקציר העלילה בלי להשתמש במידע לאחר יציאת הסרט.
63	lang_primary	קטגוריאלי	השפה הראשונה מתוך Language	מייצג את שפת הסרט המרכזית בצורה שהמודל יכול ללמוד ממנה.
64	country_primary	קטגוריאלי	המדינה הראשונה מתוך Country	מייצג את מדינת ההפקה המרכזית ומשקף הבדלים בין שווקים.
65	content_rating	קטגוריאלי	נרמול certification לקבוצות G / PG / PG-13 / R / unknown	סיווג הגבלת גיל צפייה, מאפשר למודל לזהות מי הוא קהל היעד של הסרט, קהל היעד עשוי להשפיע על הדירוג.
66	release_season	קטגוריאלי	release_month → awards / summer / dump / regular / unknown	עונת יציאה עשויה לשקף אסטרטגיית הפצה וסוג סרט.